



ESALQ

Escola Superior de Agricultura Luiz de Queiroz
Universidade de São Paulo



PROJETO DE PESQUISA DE INICIAÇÃO CIENTÍFICA

Áreas de Tecnologia Prioritária do MCTIC:

Tecnologias de Produção – Agronegócio

Tecnologias para o Desenvolvimento Sustentável: Inteligência Artificial

APLICAÇÃO DE MACHINE LEARNING PARA ANÁLISE DA QUALIDADE DA ÁGUA NA BACIA DO PCJ

APPLICATION OF MACHINE LEARNING FOR WATER QUALITY ANALYSIS IN THE
PCJ BASIN

ALUNO: GUILHERME GRAMUGLIA BETTA NUSP 13660901

ORIENTADORA: PATRICIA ANGÉLICA ALVES MARQUES NUSP 1286078

Piracicaba, SP

setembro 2025

DEPARTAMENTO DE ENGENHARIA DE BIODISSISTEMAS

Av. Pádua Dias, 11 | Caixa Postal 9 | Piracicaba, SP | 13418-900

Tel.: (19) 3447-8541 | chefeleb@usp.br | www.leb.esalq.usp.br

APLICAÇÃO DE MACHINE LEARNING PARA ANÁLISE DA QUALIDADE DA ÁGUA NA BACIA DO PCJ

Resumo: Devido a necessidade de incremento em produtividade e da grande variação do regime de chuvas provocada pelas mudanças climáticas, o número de agricultores que utilizam irrigação em seus cultivos tem aumentado nos últimos anos. A bacia do PCJ é estratégica para o abastecimento de milhões de pessoas e para atividades econômicas importantes. Métodos tradicionais são onerosos e demorados, enquanto a Inteligência Artificial (IA), por meio de seu ramo Machine Learning (ML), permite análises rápidas, identificação de padrões ocultos e suporte a decisões, mitigando riscos como entupimento de sistemas de irrigação e contaminação. Este trabalho visa organizar e analisar uma base de dados de qualidade da água da bacia PCJ, focando em variáveis como pH, turbidez, oxigênio dissolvido, nitrato, fósforo e condutividade elétrica, para auxiliar o manejo hídrico em aplicações como irrigação. Serão aplicados métodos de ML, como K-Means para identificar padrões de qualidade da água, Random Forest para classificação de qualidade e Isolation Forest para detectar anomalias, como picos de contaminação que possam comprometer sistemas de irrigação. O pré-processamento, incluindo limpeza e tratamento de valores ausentes, será realizado em Python com as bibliotecas pandas e scikit-learn, utilizando o editor Visual Studio Code. Para reprodutibilidade, os códigos serão documentados em formato de células do Jupyter Notebooks e disponibilizados em um repositório GitHub. Correlações entre variáveis serão analisadas para identificar fatores críticos, contribuindo para projetos de monitoramento e segurança alimentar.

Palavras-chave: análise exploratória; modelagem; manejo da irrigação

APPLICATION OF MACHINE LEARNING FOR WATER QUALITY ANALYSIS IN THE PCJ BASIN

Abstract: Due to the need for increased productivity and the rainfall variation in patterns caused by climate change, the number of farmers using irrigation for their crops has increased in recent years. The PCJ basin is strategic for supplying millions of people and for important economic activities. Traditional methods are costly and time-consuming, while Artificial Intelligence (AI), through its Machine Learning (ML) branch, enables rapid analysis, identification of hidden patterns, and decision support, mitigating risks such as irrigation system clogging and contamination. This project aims to organize and analyze a water quality database from the PCJ basin, focusing on variables such as pH, turbidity, dissolved oxygen, nitrate, phosphorus, and electrical conductivity, to aid water management in applications such as irrigation. ML methods such as K-Means will be applied to identify water quality patterns, Random Forest for quality classification, and Isolation Forest to detect anomalies, such as contamination spikes that could compromise irrigation systems. Preprocessing, including cleaning and missing value treatment, will be performed in Python with the pandas and scikit-learn libraries, using the Visual Studio Code editor. For reproducibility, the codes will be documented in Jupyter Notebooks cell format and made available in a GitHub repository. Correlations between variables will be analyzed to identify critical factors, contributing to monitoring and food security projects.

Keywords: exploratory analysis; modeling; irrigation management

Considerações iniciais: O aluno foi bolsista da FAPESP (2023/10336-8), de 01/09/2023 a 31/08/2024 no projeto “Déficit hídrico e retranslocação de K em cultivares de café: uma abordagem fisiológica e nutricional”. O projeto proposto aqui, faz parte do projeto de doutorado do aluno Lucas Santiago Lima, bolsista CAPES, também sob orientação da Prof. Dra. Patrícia Angélica Alves Marques, que coordenará a equipe. Há parceria com o CENA USP e C4AI. Tais interações são importantes para o bolsista por permitir ingressar na área científica e desenvolver pesquisa com amparo de pessoas treinadas. O aluno apresenta média ponderada de 8,0 sem reprovações. Como complemento da proposta, o aluno tem intenção de solicitar Bolsa Estágio de Pesquisa no Exterior no período (BEPE), para aperfeiçoar a sua formação e qualidade do projeto.

1. INTRODUÇÃO E JUSTIFICATIVA

A agricultura, além de essencial, é uma atividade econômica de alto risco, requerendo a adoção de estratégias de manejo que permitam contornar obstáculos e otimizar o uso de recursos naturais (García-Tejero et al., 2017). Devido à necessidade de incremento em produtividade e da grande variação do regime de chuvas provocada pelas mudanças climáticas, o número de agricultores que utilizam irrigação em seus cultivos tem aumentado nos últimos anos. De acordo com dados da ANA (2021), o Brasil está entre os dez países com a maior área equipada para irrigação do mundo, cerca de 8,2 milhões de hectares, responsáveis por 16% da produção agropecuária nacional. De acordo com o objetivo nº 2 de Desenvolvimento Sustentável da ONU (ODS) para 2030, a erradicação da fome através da segurança alimentar e o desenvolvimento de uma agricultura ambientalmente sustentável, relacionam-se intrinsecamente ao uso da água (ONU, 2015; 2024; ONU Brasil, 2023). Assim sendo, pesquisas de desenvolvimento dedicadas ao alcance desta meta se fazem muito importantes no cenário nacional.

Não há consenso sobre quais são as variáveis mais importantes para determinar a adequação da qualidade da água, variando em função do seu uso. Na literatura, algumas variáveis se destacam como alcalinidade; bicarbonatos; cloro livre; clorofila; cianobactéria; Condutividade

elétrica; cor; DBO; DQO; dureza; fosfato; P solúvel total; gorduras; índice de permeabilidade; IWQI; N inorgânico total; odor; óleos; oxigênio dissolvido; pH; resíduo de carbonato de sódio; salinidade; sólidos dissolvidos totais e em suspensão totais; taxa de adsorção de Na; temperatura; teor de ânions e íons tóxicos; teor de metais pesados, de microrganismos, de nutrientes, de oligoelementos e de poluentes; teor de sais de Ca, de Mg e solúveis totais; teor de Na e turbidez (Abadi; Alemayehu; Beerhe, 2024; Aliyu et al, 2017; Boqu, 2024; Cox et al., 2015; Egbueri et al, 2023; Hekpazo et al., 2025; Hoque et al., 2025; Lenntech, 2025; Ulsido; Dirigu; Berego, 2025).

A qualidade da água para irrigação está relacionada a seus efeitos prejudiciais aos solos, ao ambiente e às culturas. Dessa maneira, requer técnicas de manejo para controlar ou compensar eventuais problemas associados à sua utilização. Os parâmetros mais comumente usados para a avaliação da qualidade da água de irrigação são: condutividade elétrica (CE), concentração de ferro (Fe), pH, dureza total, sódio, cálcio, bem como a presença e a concentração de microrganismos capazes de causar entupimento de emissores (Abadi; Alemayehu; Beerhe, 2024; Ayers et al, 1985; Cordeiro, 2001; Muniz et al, 2022).

O conhecimento do pH é essencial, pois influencia os equilíbrios químicos que ocorrem naturalmente ou em processos unitários de tratamento de água. Indica a acidez ou alcalinidade da água, que deve estar em níveis adequados para as culturas. O efeito indireto também é significativo pois pode contribuir para a precipitação de elementos químicos, exercendo efeitos sobre a solubilidade dos nutrientes (Aliyu et al, 2017; Aminiyan, et al., 2018; Egbueri et al, 2023), além de tornar minerais essenciais como cálcio, magnésio e potássio indisponíveis para as plantas.

Alta concentração de nitratos na água pode levar ao crescimento vegetativo excessivo, em detrimento da floração e da frutificação, interrompendo o processo de maturação das culturas (Cropnuts Group, 2025; Boqu, 2024). Cox et al. (2015) ressaltaram que metais pesados são capazes de causar entupimentos. Ao negligenciar o monitoramento da qualidade da água utilizada na irrigação, é possível que esses fatores estejam desbalanceados, podendo acarretar uma série de problemas nos diversos setores envolvidos na produção agrícola.

Em relação ao solo, nota-se problemas como a impermeabilização e a capacidade de drenagem. Contaminantes podem degradar o solo, reduzindo sua capacidade de retenção de água e nutrientes (Cropnuts Group, 2025). Altos teores de minerais na água, especialmente o sódio, podem afetar negativamente o crescimento das plantas e a estrutura do solo (Jadhav et al., 2025), além de intensificar compactação e degradação da microbiota (Boqu, 2024).

Em relação direta ao desenvolvimento vegetal, nota-se como problemas decorrentes de má qualidade da água: a inibição da absorção de água e nutrientes, a fitotoxicidade, o desenvolvimento lento, as injúrias e/ou morte de tecidos, a menor resiliência a pragas e doenças (Boqu, 2024; Cox et al., 2015), além da dispersão de microrganismos fitopatogênicos (Cropnuts Group, 2025). A salinidade obtida pela condutividade elétrica pode causar danos ao sistema radicular (Cox et al., 2015; Boqu, 2024); queima nas bordas foliares; inibição de crescimento; maior susceptibilidade a doenças (Cox et al., 2015); alterações na estrutura, fertilidade e microbioma do solo (Abadi; Alemayehu; Berhe, 2024).

Em especial aos efeitos nos sistemas de irrigação, observa-se entupimentos físicos, químicos e biológicos, e, conseqüentemente, altos custos de manutenção e reparos (Cox et al., 2015; Muniz et al, 2022; Silva et al., 2024). Entupimentos por sólidos suspensos, como areia, terra, folhas, matéria orgânica, alga e daninhas são os parâmetros fundamentais para a escolha dos filtros, sendo importante realizar análises da qualidade da água antes da instalação e um monitoramento periódico para garantir o bom funcionamento (Cox et al., 2015).

As Bacias Hidrográficas dos Rios Piracicaba, Capivari e Jundiaí – PCJ, abrangem, total ou parcialmente, territórios de 76 municípios, sendo que 71 pertencem ao estado de SP e 5 ao estado de MG, com extensão aproximada de 300 km (Figura 1). O Plano de Recursos Hídricos das Bacias – Plano PCJ, elaborado em sua primeira versão em 2005, vem passando por um processo de revisão desde 2016, coordenado pela Agência PCJ, em articulação com os órgãos gestores de recursos hídricos com atuação nas bacias (ANA, IGAM e DAEE), e com o acompanhamento dos Comitês das Bacias PCJ (ANA, 2024; PCJ, 2024).




Figura 1. Bacia hidrográfica PCJ (Fonte: PCJ, 2024)

O clima da bacia é subtropical úmido, apresentando algumas variações. Economicamente, a bacia do Piracicaba se destaca pelo desenvolvimento da agroindústria da cana de açúcar, e pela presença de um importante polo industrial na Região Metropolitana de Campinas, com indústrias químicas, têxteis, metalúrgicas, eletrônicas, automotivas, papeleras e de celulose, assim como uma variada gama de serviços (PCJ, 2024). Atualmente, a bacia do Piracicaba está enfrentando elevadas pressões de uso de seus recursos hídricos, com a sua transposição pelo SPAC (Sistema de Produção de Água Cantareira) para fornecimento de água na SPMR (Região Metropolitana de São Paulo) (Machado; Lopes; Duarte, 2025).

Novas tecnologias permitem aumentar a eficiência de uso de água em sistemas agrícolas, com redução de seu consumo, aumento da produtividade e qualidade dos produtos agrícolas. Monitorar a qualidade hídrica é essencial, mas os métodos tradicionais são caros e lentos. A inteligência artificial (IA) pode acelerar esse processo, identificar padrões ocultos e apoiar decisões mais eficazes. Recursos como sensoriamento remoto, imagens de satélite, sensores integrados com internet das coisas (IoT), e data analytics integrado com machine learning (ML), utilizando IA para a realização de análises descritivas, exploratórias e preditivas, podem promover maior precisão, acessibilidade e rapidez nas decisões (Arroyo, 2024; SBN Software, 2025).

A introdução de modelos de IA para auxílio à tomada de decisão e o seu impacto na produção podem ajudar a reduzir riscos agrícolas e fornecer renda ao agricultor por meio de planejamento (Bertsimas; Kallus, 2020; Ramos et al., 2020). A concepção da IA foi observada na obra seminal de Alan Turing, "Computing Machinery and Intelligence" (Turing, 1950).

A IA já está transformando a agricultura, prevendo pragas e doenças, automatizando tarefas com robôs, auxiliando em programas de melhoramento genético, aumentando produtividade e reduzindo custos. Mais especificamente na área de irrigação, permite a previsão de demanda hídrica e de índice de vegetação; além da previsão do comportamento de aquíferos como disponibilidade e qualidade de água. Para desfrutar dos benefícios da utilização de tecnologias na irrigação, é indispensável ter projetos de irrigação e de cultivo bem planejados e gerenciados (Abramov, 2024; Arroyo, 2024; Workman, 2025).

O uso de IA associada a big data analytics (base de dados confiável e de período representativo), gera previsões de produtividade e otimização da alocação de recursos por meio de detecção de vazamentos, da identificação estresse vegetal, da análise da sanidade da cultura e das condições ecológicas ao redor de propriedades, prevenção de entupimentos biológicos e economia de energia (Abramov, 2024; SBN Software, 2025; Workman, 2025; Zuill, 2025).

No manejo da irrigação, a IoT permite o uso dos Smart Irrigation Systems (SIS), que asseguram a precisão da distribuição de água, e ajustam automaticamente os níveis de irrigação, elevando a eficiência hídrica do sistema (Workman, 2025). O projeto COALA que associou SIS a uma IA (Abramov, 2024), promoveu aumentos superiores a 10% da eficiência de irrigação e produtividade além da redução do custo, do uso de água e de agroquímicos.

O uso de ML para auxiliar na interpretação dos dados coletados relacionados à qualidade da água está sendo implementado para monitoramento, predição e tomada de decisões (Baziar, 2023; Workman, 2025). Porém existe uma lacuna importante na literatura sobre métodos automáticos para avaliar a qualidade da água para fins de irrigação, considerando índices ou métricas para a região do PCJ.

As técnicas de IA, especialmente aprendizado não supervisionado, podem fornecer ferramentas importantes para melhorar a extração do conhecimento e a tomada de decisões para avaliar a qualidade da água para a irrigação (Silva et al., 2024). Tradicionalmente, a análise exploratória de dados envolve técnicas estatísticas desenvolvidas por John Tukey em 1970, que permitem processar dados, e encontrar anormalidades e conexões entre eles (Morgenthaler, 2009). A realização de uma análise exploratória de dados de qualidade de água com técnicas de IA também permite extrair essas informações. Para uma análise bem elaborada, é fundamental ter uma base de dados robusta, confiável, e bem organizada, garantindo a confiabilidade e validade da análise.

2. OBJETIVOS

2.1 Objetivo geral

O objetivo deste trabalho será organizar, e analisar uma base de dados de qualidade da água da bacia hidrográfica dos rios Piracicaba, Capivari e Jundiaí (PCJ) com dados da Estação de Tratamento de Água (ETA) do rio Piracicaba coletados pelo SEMAE e parceria com o Centro de Energia Nuclear na Agricultura (CENA) utilizando métodos de ML.

2.2 Objetivos específicos

- Promover a limpeza e o pré-processamento da base de dados, incluindo tratamento de valores ausentes;
- Realizar uma análise exploratória e descritiva da base de dados;
- Realizar um estudo comparativo entre o método tradicional para remoção de outliers e o método de aprendizado de máquina;
- Desenvolver e aplicar modelos de ML para classificar e detectar anomalias, analisando variáveis de qualidade da água e suas correlações.

[illegible]

4. MATERIAL E MÉTODOS

Os dados serão obtidos do banco de dados do SEMAE (Serviço Municipal de Água e Esgoto) de Piracicaba, referentes ao período de 2009 a 2024. As variáveis disponíveis na base de dados incluem: Cor (ppm Pt Co), Turbidez (FTU), pH, Alcalinidade (ppm CaCO_3), Acidez (ppm CaCO_3), O.C. (ppm O_2), DBO (ppm O_2), Oxigênio Dissolvido (ppm O_2), Cl^- (ppm Cl^-), Dureza (ppm CaCO_3), Fe (ppm Fe), Mn (mg/L), N (ppm N), P (ppm P), Condutividade Elétrica ($\mu\text{S}/\text{cm}$), Surfactantes (mg/L), Cianobactérias (células/mL), Coliformes Totais (NMP/100 mL), Coliformes Fecais (NMP/100 mL), Clorofila ($\mu\text{g}/\text{L}$) e F (ppm F). O procedimento completo de análise segue o descrito na Figura 2.




Figura 2. Infográfico do procedimento de análise dos dados de qualidade de água do SEMAE de 2009 a 2024.

3.1. Pré-processamento

O pré-processamento será iniciado com o cálculo do percentual de dados faltantes por variável e a análise do padrão de ausência, assumido como MCAR (*Missing Completely at Random*), comum em dados hidrológicos devido a falhas aleatórias em sensores (Lepot et al., 2017). Dados ausentes serão tratados por exclusão (percentual >30%) ou imputação: média/mediana para <5% de ausentes, especialmente em variáveis assimétricas como turbidez e nitrato; e K-nearest neighbors (KNN) para 5-30%, com padronização (média = 0, desvio padrão = 1) para percentuais >15% (Troyanskaya et al., 2001; Jordanov; Tarassov, 2019).

A imputação será validada comparando estatísticas descritivas (média, mediana, desvio padrão) e o impacto no K-Means, como o coeficiente de silhueta (Lepot et al., 2017). Os dados serão normalizados com *StandardScaler* para algoritmos sensíveis a escalas (Aggarwal, 2017). Uma matriz de correlações (coeficiente de Pearson) será calculada para identificar variáveis redundantes (Hamzah et al., 2020).

3.2 Análise exploratória de dados

Será realizada uma análise exploratória, incluindo estatísticas descritivas (média, mediana, desvio padrão) e visualizações como histogramas, boxplots e mapas de calor de correlações, com foco em variáveis como pH, turbidez e nitrato. Essa etapa identificará padrões iniciais para subsidiar a detecção de *outliers* e a modelagem (Lepot et al., 2017).

3.3 Detecção de *outliers*

Será utilizado um *ensemble* de algoritmos (KNN, Isolation Forest, Local Outlier Factor) com votação por maioria ou *scores* agregados, capturando anomalias globais, locais e contextuais (Aggarwal, 2017). O parâmetro *contamination* será ajustado entre 0,05 e 0,1 com base em validação cruzada (Zhao et al., 2020a,b). A regra do IQR será comparada ao ensemble para avaliar robustez, especialmente para picos de nitrato ou turbidez (Aggarwal, 2017).

3.4 Modelagem com Machine Learning

Serão aplicados modelos de Machine Learning (ramo da Inteligência Artificial) em etapas sequenciais para analisar a qualidade da água:

K-Means (Clustering): Os dados normalizados serão preparados selecionando variáveis relevantes (ex.: pH, condutividade elétrica, nitrato). O algoritmo será aplicado para agrupar os dados por similaridade, testando *n_clusters* de 2 a 10, definido pelo método do cotovelo (Kaufman; Russeeuw, 1990). O objetivo é identificar padrões espaciais ou temporais (ex.: regiões com alta turbidez) para manejo hídrico.

Random Forest (Classificação): Os dados serão divididos em treinamento (80%) e teste (20%). O modelo será treinado com *n_estimators*=100 e profundidade limitada para evitar *overfitting*, classificando a qualidade da água (ex.: adequada/inadequada, conforme Resolução CONAMA 357/2005, Brasil, 2012).

Isolation Forest (Detecção de Anomalias): Após clustering, os dados serão processados para detectar anomalias isoladas, ajustando *contamination* (0,05–0,1) com base na análise exploratória. O algoritmo identificará picos de contaminação (ex.: fósforo elevado), focando em eventos críticos.

3.5. Validação dos resultados

A validação dos modelos será conduzida de maneira integrada, combinando abordagens quantitativas (métricas numéricas para medir desempenho) e visuais (gráficos para inspeção qualitativa), conforme práticas consolidadas na ciência da computação. Planeja-se aplicar métodos específicos para cada algoritmo de Machine Learning, garantindo que a análise da qualidade da água seja robusta. Essa estratégia evita viés e *overfitting*, com referências clássicas e recentes para embasar as escolhas.

3.5.1. K-Means

Validação quantitativa: Calcularemos o coeficiente de silhueta, proposto por Rousseeuw (1987), para medir coesão intra-cluster e separação inter-cluster (valores $>0,5$ indicam clusters efetivos).

A fórmula para um ponto i é (Eq. 1). Complementarmente, o método do cotovelo otimizará o número de clusters k , analisando a soma dos quadrados intra-cluster (WCSS), conforme Jain & Dubes (1988) (Eq. 2):

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (1)$$

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2 \quad (2)$$

onde $a(i)$ representa a distância média intra-cluster, e $b(i)$ a menor distância inter-cluster.

Validação visual: Scatter plots (ex.: pH vs. turbidez, coloridos por *clusters*) permitirão uma inspeção intuitiva da separação, facilitando a identificação de grupos relevantes para manejo.

3.5.2. Random Forest

Validação quantitativa: Avaliaremos a performance com acurácia e F1-Score, consolidadas por Biau & Scornet (2016) para Random Forest. A acurácia é dada por (Eq. 3). O F1-Score, que equilibra precisão e *recall* conforme Biau & Scornet (2016) e Powers (2020) (Eq. 4). A Validação cruzada ($k=5$) assegurará generalização (Pedregosa et al., 2011).:

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} = \frac{Previsões corretas}{Total de previsões} \quad (3)$$

$$F1 - Score = 2 * \frac{Precisão * Recall}{Precisão + Recall} \quad (4)$$

onde, VP (Verdadeiro Positivo); VN (Verdadeiro Negativo); FP (Falso Positivo); e FN (Falso

Negativo); $Precisão = \frac{VP}{VP + FP}$ e $Recall$ (Sensibilidade) $= \frac{VP}{VP + FN}$ (Powers, 2020).

Validação visual: Uma matriz de confusão, com linhas (classes verdadeiras) e colunas (classes preditas), exibirá VP, VN, FP e FN, destacando erros (ex.: falsos positivos em qualidade inadequada) para irrigação.

A matriz de confusão apresenta as frequências de classificação para cada classe do modelo (Congalton, 1991). Em uma matriz de confusão, a frequência observada na diagonal (n_{ii}) representa os elementos classificados corretamente. A coluna marginal (n_{i+}) representa o total de elementos classificados para uma categoria i . A linha marginal (n_{+i}) representa o total de elementos de referência amostrados para uma categoria i (Tabela 1).

Tabela 1. Arquitetura da matriz de confusão.

Rótulos	Preditos		
	Verdadeiro		Falso
	Verdadeiro	VV	FV
	Falso	FF	VF

3.5.3. Isolation Forest:

Validação quantitativa: Ajustaremos a taxa de contaminação (0,05-0,1), proposta por Liu et al. (2008) como métrica clássica para o Isolation Forest, que isola anomalias por meio de árvores de decisão aleatórias - caminhos mais curtos indicam *outliers*. Essa abordagem recente será otimizada com validação cruzada para dados ambientais (Zhao et al., 2020a,b).

Validação visual: Scatter plots destacando anomalias (ex.: pontos vermelhos para picos de nitrato) oferecerão uma inspeção qualitativa de eventos críticos, como contaminação por fósforo.

6. DOCUMENTAÇÃO E REPRODUTIBILIDADE

A documentação e a reprodutibilidade serão priorizadas para garantir que os resultados do estudo possam ser replicados por outros pesquisadores. Os códigos serão desenvolvidos e documentados em Jupyter Notebooks, uma ferramenta interativa que integra código Python, texto explicativo, equações e visualizações em um único arquivo executável. Cada notebook será organizado em células comentadas, com seções dedicadas a etapas específicas: pré-processamento, análise exploratória, detecção de outliers, modelagem e validação. O repositório será hospedado no GitHub, uma plataforma de versionamento que registra alterações no código e colaborações. O repositório incluirá:

- **README.md:** Um arquivo de apresentação com instruções de instalação, execução dos notebooks e descrição do projeto; e
- **Relatórios:** Arquivos gerados, como PDFs de resultados de validação (ex.: matriz de confusão), serão incluídos para documentar *outputs*.

REFERÊNCIAS BIBLIOGRÁFICAS

ABADI, H.T.; ALEMAYEHU, T.; BERHE, B. Assessing the suitability of water for irrigation purposes using irrigation water quality indices in the Irob catchment, Tigray, Northern Ethiopia. *Water Quality Research Journal*, v.60, n.1, p.177-195, 2024.

ABRAMOV, M. *Precision irrigation: how AI can optimize water usage in agriculture*. 2024. Disponível em: <https://keymakr.com/blog/precision-irrigation-how-ai-can-optimize-water-usage-in-agriculture/>.

AGGARWAL, C. C. (2017). *Outlier Analysis* (2ed.). Springer International Publishing AG, 2017. 466p.

AGGARWAL, C.C. *Outlier Analysis*. Yorktown Heights: Springer Cham, 2017. 2ed. 466p. <https://doi.org/10.1007/978-3-319-47578-3>

- ALIYU, T. et al. Assessment of the presence of metals and quality of water used for irrigation in Kwara State, Nigeria. *Pollution*, v.3, n.3, p.461-470, 2017.
- AMINIYAN, M.M. et al. Evaluation of multiple water quality indices for drinking and irrigation purposes for the Karoon river, Iran. *Environ. Geochem. Health*, v.40, n.6, p.2707-2728, 2018.
- ANA (Agência Nacional de Águas e Saneamento Básico - Brasil) *PCJ*. 2024 Disponível em: <https://www.gov.br/ana/pt-br/assuntos/gestao-das-aguas/planos-de-recursos-hidricos/planos-de-recursos-hidricos-de-bacias-hidrograficas/planos-de-bacias-hidrograficas-interfederativas/pcj>
- ANA (Agência Nacional de Águas e Saneamento Básico - Brasil). *Atlas irrigação: uso da água na agricultura irrigada*. 2.ed., Brasília: ANA, 2021. 130p. Disponível em: <https://biblioteca.ana.gov.br>
- ARROYO, M.M. *How artificial intelligence (AI) can help optimize irrigation water use*. 2024. Disponível em: <https://smartwatermagazine.com/blogs/manuel-martin-arroyo/how-artificial-intelligence-ai-can-help-optimise-irrigation-water-use>.
- AYERS, R.S. et al *Water Quality for Agriculture*; Food and agriculture organization of the United Nations Rome, FAO: Rome, Italy, 1985; Volume 29.
- BAZIAR, M. Prediction of groundwater nitrate variations using AdaBoost approach. *Journal of Research in Environmental Health*, v.9, n.3, p.279-289, 2023.
- BERTSIMAS, D.; KALLUS, N. From predictive to prescriptive analytics. *Management Science*, v.6, n.3, p.1025-1044, 2020.
- BIAU, G.; SCORNET, E. A random forest guided tour. *Test*, v.25, n.2, p.197–227, 2016.
- BOQU. *The importance of real-time water quality analysis in agriculture*. 2024. Disponível em: <https://www.boquinstrument.com/a-the-importance-of-real-time-water-quality-analysis-in-agriculture.html>.
- BRASIL. *Conselho Nacional do Meio Ambiente (CONAMA)*. Resolução nº 450, de 6 de março de 2012. Altera os arts. 9º, 16, 19, 20, 21 e 22, e acrescenta o art. 24-A à Resolução CONAMA nº 362, de 23 de junho de 2005. Diário Oficial da União, Brasília, DF, 7 mar. 2012.

- CONGALTON, R.G. A review of assessing the accuracy of classifications of remotely sensed data. *Remote Sensing of Environment* .v.37, n.1, 1991, p.35-46.
- CORDEIRO, G.G. *Qualidade de água para fins de irrigação* (Conceitos básicos e práticas). Petrolina, PE: Embrapa SemiÁrido, 2001. 32 p. (Documentos; 167).
- COX, D. et al. *Greenhouse Crops and Floriculture Program*. University of Massachusetts Amherst: 2015, Disponível em: <https://www.umass.edu/agriculture-food-environment/greenhouse-floriculture/greenhouse-best-management-practices-bmp-manual/water-quality-for-crop-production>.
- CROPNUTS GROUP. *Importance of water quality in agriculture*. 2025. Disponível em: <https://cropnuts.com/importance-of-water-quality-in-agriculture/>.
- EGBUERI, J.C. et al. A multi-criteria water quality evaluation for human consumption, irrigation and industrial purposes in Umunya area, southeastern Nigeria. *Int. J. Environ. Anal. Chem.*, v.103, p.3351–3375, 2023.
- GARCÍA-TEJERO, I.F. et al. Assessing plant water status in a hedgerow olive orchard from thermography at plant level. *Agricultural Water Management*, v.188, p.50-60, 2017.
- HAMZAH, F.B. et al. Imputation methods for recovering streamflow observation: A methodological review. *Cogent Environmental Science*, v.6, n.1, 1745133, 2020.
- HEKPAZO, R.C.M. et al. Dynamics of the optical water quality parameters in the Lake Nokoué and Cotonou Channel complex (Benin). *Environmental Challenges*, v.19, p.101126, 2025.
- HOQUE, A. et al. Modeling water quality parameters in marine ecosystems affected by oxygen deficiency. *Modeling Earth Systems and Environment*, v.11, n.3, p.11-206, 2025.
- JADHAV, A. et al. Consequences of irrigation water and soil quality: an overview. *Asian Journal of Soil Science and Plant Nutrition*, v.11, n.1, p.435–453, 2025.
- JAIN, A.K.; DUBES, R.C. *Algorithms for Clustering Data*. Prentice Hall. Division of Simon and Schuster One Lake Street Upper Saddle River, NJUnited States, 1988. 320p.

- JORDANOV, I; TARASSOV, E. K-nearest neighbors imputation for missing data in datasets. *2019 IEEE International Conference on Information Technologies (InfoTech-2019)*, p.1–4, 2019.
- KAUFMAN, L.; ROUSSEEUW, P. J. Finding Groups in Data: An Introduction to Cluster Analysis. Publisher: John Wiley, New York 1990. 788p.
- LENNTECH. *Irrigation water quality*. 2025. Disponível em: <https://www.lenntech.com/industries/irrigation-water-quality.htm>.
- LEPOT, M. et al. Interpolation in time series: An introductory overview of existing methods, their performance criteria and uncertainty assessment. *Water*, v.9, n.10, p.796, 2017.
- MACHADO, R.; LOPES, T.; DUARTE, S. Projected climate and land-use change impacts on streamflow: the case study of Piracicaba basin – Brazil. *International Journal of River Basin Management*, p.1–16, 2025.
- MORGENTHALER, S. *Exploratory data analysis*. Wiley Interdisciplinary Reviews: Computational Statistics, v.1, n. 1, 33-44, 2009.
- MUNIZ, G.L. et al. Influence of suspended solid particles on calcium carbonate fouling in dripper labyrinths. *Agric. Water Manag.*, v.273, artigo 107890, 2022.
- ONU BRASIL. *Objetivos de Desenvolvimento Sustentável*. 2023. Disponível em: <https://brasil.un.org/pt-br/sdgs/2>.
- ONU Department of Economic and Social Affairs, Population Division *Population 2030: Demographic challenges and opportunities for sustainable development planning* (ST/ESA/SER.A/389).2015. Disponível em: <https://population.un.org/wpp/>
- ONU. *Water – at the center of the climate crisis*. 2024. Disponível em: <https://www.un.org/en/climatechange/science/climate-issues/water>.
- PCJ Agência das Bacias do PCJ. 2024 Disponível em: <https://agencia.baciaspcj.org.br/bacias-pcj/localizacao/>
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v.12, p.2825–2830, 2011.

- POWERS, D.M.W. Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, v.2, n.1, p.37-63, 2020.
- RAMOS, C.D. et al. Malnutrition causal modeling analytics for Mandaluyong City's Nutrition Committee. *Test Engineering and Management*, v.82, p.11941, 2020.
- ROUSSEEUW, P.J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v.20, p.53–65. 1987.
- SBN SOFTWARE. *How can technology enhance water quality monitoring practices?* 2025. Disponível em: <https://sbnsoftware.com/blog/how-can-technology-enhance-water-quality-monitoring-practices/>.
- SILVA, R.F.et al. A Data-Driven Method for Water Quality Analysis and Prediction for Localized Irrigation. *AgriEngineering*, v.6, n.2, p.1771-1793, 2024.
- TROYANSKAYA, O., et al. Missing value estimation methods for DNA microarrays. *Bioinformatics*, v.17, n.6, p.520-525, 2021.
- TURING, A. M. Computing Machinery and Intelligence. *Mind*, v.49, p. 433-460, 1950.
- ULSIDO, M.D.; DINIGU, F.B.; BEREGO, Y.S. Uncovering the Effect of Multiple Wet Coffee Processing Industries' Effluents on River Water Quality Parameters. *Environmental Forensics*, p.1-13, 2025.
- WORKMAN, J. *Smart Farming Using AI, IoT, and Remote Sensing*. 2025. Disponível em: <https://www.spectroscopyonline.com/view/smart-farming-using-ai-iot-and-remote-sensing>.
- ZHAO, Y et al. PyOD: A Python Toolbox for Scalable Outlier Detection. *Journal of Machine Learning Research*, v.20, n.96, p.1-7, 2020b.
- ZHAO, Y., et al. COPOD: Copula-Based Outlier Detection. *IEEE International Conference on Data Mining (ICDM)*. 2020a. Disponível em: <https://arxiv.org/abs/2009.09463>
- ZUILL, J. *Remote sensing: can it help water management on farm?* 2025. Disponível em: <https://www.farmingandwaterscotland.org/resource/remote-sensing-can-it-help-water-management-on-farm/>.