

Relatório final — Resultados

Aplicação de Machine Learning – Qualidade da água na bacia do PCJ
SEMAE Piracicaba, 2009–2024 · base de modelagem: 192 meses (Méd.)

K-Means : melhor $k=2$, silhueta=0.279

Random Forest : acurácia=0.692, $F1=0.333$, precisão=0.600, recall=0.231

Isolation Forest : contamination calibrado=0.08 (estabilidade=0.818)

Validação da imputação (silhueta K-Means): complete-case=0.203 vs imputado=0.279



Random Forest — Matriz de confusão

Unnamed: 0	pred_baixa severidade	pred_alta severidade
real_baixa severidade	24	2
real_alta severidade	10	3


Validação da imputação — impacto na silhueta

conjunto	n	melhor_k	silhueta
complete-case	126	3	0.203
imputado	192	2	0.2792


K-Means — cotovelo e silhueta




Random Forest — matriz de confusão




Random Forest — importância das variáveis




Isolation Forest — anomalies



Calibração de contamination (CV)



Outliers confirmados — violações CONAMA



Ressalva: a CONAMA 357/2005 limita o Fe DISSOLVIDO (0,3 mg/L), mas o SEMAE mede Fe TOTAL → a violação de Fe é só indicativa (hachurada) e não conta no rótulo das linhas.
Mn (0,1) é limite de Mn total e coincide com a medição.

Correlação entre variáveis

