

Resultados — Aplicação de Machine Learning para análise da

Relatório de resultados do projeto de Iniciação Científica (IC, Guilherme). Segue a estrutura metodológica do projeto (seções 3.1 a 3.5, ver pdf do projeto FAPESP), apresentando, para cada etapa, os resultados obtidos, as figuras e tabelas correspondentes e a sua interpretação.

Base de dados. Boletins físico-químicos e bacteriológicos do SEMAE-Piracicaba (água bruta do rio Piracicaba), série 2009-2024. Cada página do PDF traz, por mês, três estatísticas (Mín./Méd./Máx.). A tabela de modelagem usa a estatística Méd. mensal, resultando em 192 observações (16 anos × 12 meses) × 23 variáveis físico-químicas/bacteriológicas. Todos os modelos usam semente fixa (random_state=42); figuras em reports/figures/, tabelas em reports/tables/.

3.1 Pré-processamento

3.1.1 Análise de dados faltantes e padrão de ausência

Calculou-se o percentual de faltantes por variável. A distribuição é fortemente desigual: 7 variáveis têm >30% de ausências (medições esporádicas no boletim), enquanto os parâmetros físico-químicos básicos têm <5%.




Figura 1. Percentual de valores ausentes por variável (192 meses). Sólidos

totais e surfactantes são quase nunca medidos (~99%); nutrientes (P, N) e amônia ficam acima de 75%; pH, turbidez e cor têm <1%.




Figura 2. Matriz de ausência (linhas = meses, colunas = variáveis). Evidencia

que as ausências são estruturais por período — p. ex., N, P e amônia só passam a ser medidos de forma regular a partir de ~2018-2021.




Figura 3. Cobertura temporal: quando cada variável passou a ser medida. Confirma

que a ausência não é aleatória no tempo (mudança de protocolo do laboratório).




Figura 4. Correlação entre padrões de ausência: variáveis que “somem juntas”

(nutrientes e bacteriológicos), reforçando ausência por blocos de protocolo.

Teste da hipótese MCAR (Little). O projeto assume Missing Completely At Random. O teste de Little resultou em $\chi^2 \approx 327,6$ (gl = 269), $p \approx 0,008$. Como $p < 0,05$, a hipótese MCAR é rejeitada: os faltantes não são completamente aleatórios — coerente com as Figuras 2-3 (ausência ligada a mudança de protocolo, não a falha aleatória de sensor). A imputação segue as regras declaradas no projeto, mas esta limitação fica registrada para a interpretação dos resultados.

3.1.2 Decisão de tratamento por variável

Aplicou-se a árvore de decisão do projeto: $>30\% \rightarrow$ excluir; $5-30\% \rightarrow$ KNN ($k=5$, weights="distance", padronizado quando faltantes $>15\%$); $<5\% \rightarrow$ média (simétrica) ou mediana (assimétrica, $|\text{skew}|>1$).

Tabela 1. Decisão de imputação por variável (ordenada por % de faltantes).

Variável	% faltantes	skew	Decisão
S.T. (mg/L)	99,5	—	EXCLUIR
Surfact. (mg/L)	99,5	—	EXCLUIR
DBO (ppm O ₂)	96,4	2,64	EXCLUIR
P (ppm P)	90,6	0,45	EXCLUIR
N (ppm N)	89,1	3,83	EXCLUIR
Amônia (mg/L)	75,5	0,23	EXCLUIR
C.T. (NMP/100mL)	60,9	3,27	EXCLUIR
C.F. (NMP/100mL)	19,8	3,77	KNN
F (ppm F)	18,8	0,63	KNN
CLOROFILA (µg/L)	7,8	6,11	KNN
Cianobactérias (cel/mL)	7,3	3,64	KNN
ALC. (ppm CaCO ₃)	5,2	1,80	KNN
AC. (ppm CaCO ₃)	5,2	3,82	KNN
Mn (mg/L)	3,6	2,41	Mediana
Fe (ppm Fe)	3,6	2,67	Mediana
DUR. (ppm CaCO ₃)	3,6	1,41	Mediana
Cl ⁻ (ppm Cl ⁻)	3,6	3,92	Mediana
O.C. (ppm O ₂)	3,6	2,85	Mediana
O.D. (ppm O ₂)	2,6	0,18	Média
Cond. (µS/cm)	1,6	1,52	Mediana
TURB. (FTU)	0,5	1,98	Mediana
pH	0,5	0,64	Média
COR (ppm Pt Co)	0,5	3,43	Mediana

Resultado: 7 variáveis excluídas e 16 mantidas para modelagem. △ A regra descarta justamente N, P e amônia (nutrientes), relevantes para irrigação — conflito documentado; mitigação possível é um pipeline alternativo 2018-2024.

3.1.3 Validação da imputação (impacto no K-Means)

Além de comparar média/mediana/desvio antes e depois (sem distorções relevantes nas 16 mantidas), avaliou-se o impacto da imputação na estrutura de clusters (coeficiente de silhueta), como pede o projeto.

Tabela 2. Impacto da imputação na silhueta do K-Means.

Conjunto	n	melhor k	silhueta
complete-case (sem imputar)	126	3	0,203
imputado (192 meses)	192	2	0,279

A imputação não degradou a estrutura — a silhueta do conjunto imputado (0,279) é até superior à do subconjunto complete-case (0,203), indicando que recuperar as linhas com faltantes reforçou uma separação consistente em 2 grupos.

3.1.4 Padronização e correlação

Os dados foram padronizados com StandardScaler (média 0, desvio 1) para os algoritmos sensíveis a escala (K-Means, KNN, LOF). A matriz de correlação de Pearson identifica redundâncias entre variáveis.




Figura 5. Correlação de Pearson entre as 16 variáveis mantidas. Destacam-se as

associações esperadas: dureza × condutividade × alcalinidade (mineralização conjunta) e cor × turbidez (material particulado). Pares muito correlacionados são candidatos a redundância na modelagem.

3.2 Análise exploratória de dados

A análise descritiva (média, mediana, desvio) e as visualizações por variável subsidiam a detecção de outliers e a modelagem. Os boxplots padronizados (z-score) permitem comparar variáveis em escalas muito diferentes na mesma figura.




Figura 6. Boxplots padronizados (z-score) das 23 variáveis, com outliers do IQR

em vermelho. Variáveis fortemente assimétricas e com caudas longas (cor, ferro, clorofila, coliformes) concentram a maioria dos pontos extremos — sinalizando os parâmetros mais propensos a

“picos” de qualidade.




Figura 7. Séries temporais de variáveis-chave com os meses sinalizados por categoria. Os picos se concentram em períodos específicos (ver §3.3).

3.3 Detecção de outliers — método tradicional vs. ensemble de ML

Comparou-se a regra tradicional IQR (e a variante robusta MAD) com o ensemble multivariado (Isolation Forest + LOF + KNN, voto por maioria $\geq 2/3$), todos com contamination = 0,07, sobre a camada multivariada (10 variáveis com $\leq 5\%$ de faltantes, 180 observações complete-case, padronizadas).

3.3.1 Comparação quantitativa entre métodos

Tabela 3. Comparação interna dos métodos de detecção (180 obs; sem rótulo verdadeiro, usa-se calibração ao alvo de 7%, alinhamento com a crise do Cantareira 2014-2016 e concordância entre métodos).

Método	nº flags	taxa	dist. calibração ↓	recall crise	precisão crise	concordância
IQR	91	0,474	0,404	0,639	0,253	0,265
MAD	96	0,500	0,430	0,667	0,250	0,259
IForest	13	0,068	0,002	0,222	0,615	0,484
LOF	13	0,068	0,002	0,250	0,692	0,484
KNN	13	0,068	0,002	0,222	0,615	0,534
Ensemble	12	0,063	0,008	0,222	0,667	0,550

Comparação interna de métodos — destaque = melhor calibração

método	n_flags	taxa_observada	dist_calibração	recall_crise_2014_201	precisão_crise	concordância_média
IQR	91	0.474	0.404	0.639	0.253	0.265
MAD	96	0.5	0.43	0.667	0.25	0.259
IForest	13	0.068	0.002	0.222	0.615	0.484
LOF	13	0.068	0.002	0.25	0.692	0.484
KNN	13	0.068	0.002	0.222	0.615	0.534
Ensemble (voto)	12	0.062	0.008	0.222	0.667	0.55

Figura 8. Tabela-resumo da comparação (destaque = melhor calibração). Os métodos univariados (IQR/MAD) marcam ~25% das observações — muitas, com baixa precisão — pois sinalizam a linha sempre que uma única variável é extrema. Os métodos multivariados ficam bem calibrados (~7%) e mais precisos contra o evento conhecido.




Figura 9. Matriz de Jaccard: os multivariados concordam fortemente entre si; IQR e MAD formam um grupo à parte (muito sensível).




Figura 10. Sobreposição IQR u MAD u Ensemble — o ensemble é praticamente um subconjunto “robusto” dos univariados.




Figura 11. Percentual de meses marcados por ano. Há concentração de anomalias no período da crise do Cantareira (2014-2016), usado como validação externa empírica.




Figura 12. Heatmap variável × método: quais variáveis cada método mais “ataca”.

3.3.2 Detecção por método nos dados normalizados




Figura 13. Detecção por método, projetada em PCA-2D (PC1+PC2 ≈ 63% da variância)

dos dados padronizados; 7º painel colore os pontos pelo nº de violações CONAMA (sem Fe). IQR/MAD pintam de vermelho até o miolo da nuvem (univariados, agressivos); IForest/LOF/KNN/Ensemble marcam apenas a periferia — onde também se concentram as maiores cargas de não conformidade legal. Confirma a complementaridade das duas lentes.

3.3.3 Calibração de contamination por validação cruzada

O parâmetro contamination (faixa 0,05–0,1 do projeto) foi calibrado por estabilidade das flags entre folds (Jaccard médio, proxy de robustez sem rótulo).

Tabela 4. Calibração de contamination (Isolation Forest, 5-fold).

contamination	nº flags	taxa	estabilidade (Jaccard)
0,05	9	0,050	0,770
0,06	11	0,061	0,800
0,07	13	0,072	0,808
0,08	15	0,083	0,818
0,09	17	0,094	0,772
0,10	18	0,100	0,771




Figura 14. Estabilidade vs. contamination. O máximo de estabilidade ocorre em 0,08 — escolha data-driven dentro da faixa do projeto, substituindo o valor arbitrário de 0,07.

3.3.4 Outliers confirmados (consenso + domínio + evento)

Como não há ground truth, definiu-se outlier confirmado = marcado por ≥ 4 dos 6 métodos e com ≥ 1 violação CONAMA 357/2005 (descontando o Ferro — ver nota). Resultado: 12 de 180 observações.

Tabela 5. Outliers confirmados (12 meses).

Ano/Mês	nº métodos	viol. CONAMA	viol. sem Fe	Métodos
2009 Fev	6	6	5	todos
2009 Dez	6	6	5	todos
2014 Jul	6	5	4	todos
2014 Ago	6	5	4	todos
2014 Set	6	6	5	todos
2014 Out	6	6	5	todos
2014 Nov	6	6	5	todos
2016 Fev	6	5	4	todos
2016 Jun	6	5	4	todos
2016 Nov	6	6	5	todos
2011 Jan	5	6	5	IQR, MAD, IForest, KNN, Ensemble
2017 Abr	5	5	4	IQR, MAD, LOF, KNN, Ensemble




Figura 15. Parâmetros que cada outlier confirmado viola (vermelho), com o valor medido anotado; a coluna Fe é hachurada (violação só indicativa, ver nota). Os disparadores recorrentes são cor, oxigênio dissolvido baixo, clorofila e coliformes.




Figura 16. Violações com vs. sem o Ferro. Mesmo descontando o Fe, os 12 meses mantêm 4-5 violações reais: a confirmação não depende do parâmetro enviesado.




Figura 17. Distribuição temporal dos confirmados: 8 dos 12 caem em 2014/2016 (crise do Cantareira) — convergência entre estatística, norma legal e evento histórico.

Nota sobre o Ferro. A CONAMA 357/2005 limita o Fe dissolvido (0,3 mg/L), mas o SEMAE mede Fe total → as violações de Fe estão superestimadas e foram tratadas como indicativas. O Manganês (0,1) é limite de Mn total e coincide com a medição (sem viés). Limites verificados contra os Art. 14 e 15 da Resolução.

3.4 Modelagem com Machine Learning

3.4.1 K-Means (agrupamento)

Testou-se $n_{clusters}$ de 2 a 10. O número de clusters foi escolhido pela silhueta (máxima em $k=2$), com o método do cotovelo como apoio (joelho em $k \approx 3$).

Tabela 6. Varredura de k (WCSS e silhueta).

k	WCSS	silhueta
2	2492,2	0,279
3	2084,9	0,227
4	1969,9	0,165
5	1861,5	0,130
6	1737,5	0,115
7	1708,3	0,099
8	1551,7	0,115
9	1506,5	0,111
10	1381,6	0,115




Figura 18. Método do cotovelo (WCSS) e coeficiente de silhueta vs. k. A silhueta

máxima (0,279) fica abaixo de 0,5 — clusters existem, mas com separação moderada (esperado em série ambiental contínua).




Figura 19. Dispersão pH x turbidez colorida por cluster — inspeção visual da separação.

Tabela 7. Perfil dos clusters (média de cada variável por grupo).

Variável	Cluster 0 (n=42)	Cluster 1 (n=150)
COR (ppm Pt Co)	76,6	132,5
TURB. (FTU)	20,8	75,3
pH	7,50	7,28
ALC. (ppm CaCO ₃)	96,9	53,9
O.C. (ppm O ₂)	10,7	7,9
O.D. (ppm O ₂)	2,55	3,28
Cl ⁻ (ppm Cl ⁻)	72,1	36,8
DUR. (ppm CaCO ₃)	69,8	49,4
Cond. (μS/cm)	548,3	264,9
Cianobactérias (cel/mL)	20.799	7.873
CLOROFILA (μg/L)	81,2	25,3

Interpretação. O K-Means separa dois regimes de qualidade pelo eixo mineralização x turbidez:

- Cluster 0 (22%, n=42) — água mineralizada e eutrofizada: alta condutividade (548 μS/cm), alcalinidade, dureza, cloreto, clorofila e cianobactérias, com baixa turbidez (20,8 FTU). É mais frequente no período seco (64% das suas amostras), quando há concentração de solutos e floração de algas.
- Cluster 1 (78%, n=150) — água turva e diluída: alta turbidez (75,3 FTU) e cor, baixa condutividade (265 μS/cm); distribui-se quase igualmente entre as estações (54% úmida, 46% seca).

A associação com a sazonalidade é moderada, não determinística — ambos os regimes ocorrem nas duas estações (cluster 0: 64% seca / 36% úmida; cluster 1: 46% / 54%) —, mas o contraste mineralização x turbidez é nítido e operacionalmente útil: o regime turvo exige filtragem; o eutrofizado pede

atenção a algas/cianotoxinas e a entupimento biológico de emissores.

3.4.2 Random Forest (classificação)

Rótulo. O rótulo estrito CONAMA (“viola qualquer parâmetro”) é degenerado em água bruta (as 192 amostras seriam “inadequadas”, pois a norma classifica o corpo d’água, não a água tratada). Adotou-se então a severidade = nº de parâmetros violados binarizado pela mediana → classes baixa (126) e alta (66). Para evitar data leakage, as variáveis usadas na regra de rótulo foram removidas das features; o classificador usa apenas as 5 não normalizadas: ALC, AC, O.C., DUR, Cond. Split 80/20 estratificado, $n_estimators=100$, $max_depth=10$, $class_weight="balanced"$, validação cruzada $k=5$.

Tabela 8. Métricas do Random Forest (conjunto de teste).

Acurácia	Precisão	Recall	F1	CV-F1 (k=5)
0,692	0,600	0,231	0,333	0,472




Figura 20. Matriz de confusão. De 13 meses de alta severidade no teste, o

modelo acerta 3 (recall 0,23) e perde 10 — modelo conservador: boa precisão (0,60), baixa sensibilidade. Esperado, pois apenas 5 variáveis não normalizadas tentam prever uma severidade governada por outras (cor, OD, clorofila...).




Figura 21. Importância das variáveis. Alcalinidade (0,24) e condutividade

(0,24) lideram, seguidas de oxigênio consumido (0,20), dureza (0,18) e acidez (0,14)— ou seja, o grau de mineralização da água é o melhor preditor (indireto) da severidade de não conformidade.

3.4.3 Isolation Forest (detecção de anomalias)

Aplicado às 192 observações padronizadas, com contamination calibrado.

Resultado: taxa de anomalias = 0,073 (14 de 192 meses). As anomalias coincidem com os picos identificados em §3.3 (eventos de 2014/2016 e picos de cor/ferro de 2009).




Figura 22. Dispersão com as anomalias (vermelho) destacadas — inspeção qualitativa de eventos críticos (picos de mineralização e de material particulado).

3.5 Validação consolidada

Tabela 9. Síntese quantitativa dos três modelos.

Modelo	Métrica principal	Valor	Leitura
K-Means	silhueta (k=2)	0,279	regimes (turvo/diluído x mineralizado/eutrofizado); separação n
Random Forest	F1 / acurácia	0,333 / 0,692	editor conservador; mineralização explica parte da severid
Isolation Forest	taxa de anomalias	0,073	14 meses críticos, alinhados à crise 2014-2016
Outliers (ensemble)	nº confirmados	12/180	consenso + violação CONAMA + evento histórico
contamination	calibrado (CV)	0,08	estabilidade Jaccard 0,818
Imputação	silhueta imp. vs CC	0,279 vs 0,203	imputação preservou a estrutura
MCAR (Little)	p-valor	0,008	MCAR rejeitado (ausência não aleatória)

Convergência das evidências. Os três caminhos independentes — agrupamento (K-Means), detecção estatística (ensemble/Isolation Forest) e checagem regulatória (CONAMA) — apontam para os mesmos períodos críticos (sobretudo 2014–2016), o que dá robustez ao diagnóstico. Para o manejo de irrigação na bacia PCJ, os resultados indicam dois regimes operacionais distintos e um conjunto pequeno e bem caracterizado de meses de risco, úteis para priorizar monitoramento e prevenção de entupimentos.

Limitações dos resultados

- MCAR rejeitado: a imputação assume aleatoriedade que os dados não confirmam; recomenda-se análise de sensibilidade.
- Nutrientes excluídos: N, P e amônia (>30% faltantes) saíram da modelagem, apesar de relevantes para irrigação — um pipeline 2018–2024 os recuperaria.
- Ferro total x dissolvido: violações de Fe são apenas indicativas (tratadas como tal).
- Random Forest conservador: baixo recall; rótulo de severidade é um proxy da aptidão real para irrigação (a CONAMA 357 não é específica para uso agrícola— ver FAO 29 / Ayers & Westcot como complemento futuro).
- Água bruta: os limites CONAMA classificam o corpo d’água, não a água tratada; por isso a leitura é de severidade relativa, não de aptidão absoluta.

Referências

ABADI, H.T.; ALEMAYEHU, T.; BERHE, B. Assessing the suitability of water for irrigation purposes using irrigation water quality indices in the Irob catchment, Tigray, Northern Ethiopia. *Water Quality Research Journal*, v.60, n.1, p.177-195, 2024.

AGGARWAL, C.C. *Outlier Analysis*. 2.ed. Springer Cham, 2017. 466p. <https://doi.org/10.1007/978-3-319-47578-3>

ALIYU, T. et al. Assessment of the presence of metals and quality of water used for irrigation in Kwara State, Nigeria. *Pollution*, v.3, n.3, p.461-470, 2017.

AMINIYAN, M.M. et al. Evaluation of multiple water quality indices for drinking and irrigation purposes for the Karoon river, Iran. *Environ. Geochem. Health*, v.40, n.6, p.2707-2728, 2018.

ANA (Agência Nacional de Águas e Saneamento Básico). PCJ. 2024.

ANA (Agência Nacional de Águas e Saneamento Básico). *Atlas irrigação: uso da água na agricultura irrigada*. 2.ed. Brasília: ANA, 2021. 130p.

AYERS, R.S. et al. *Water Quality for Agriculture*. FAO: Rome, 1985. v.29.

BIAU, G.; SCORNET, E. A random forest guided tour. *Test*, v.25, n.2, p.197-227, 2016.

BRASIL. Conselho Nacional do Meio Ambiente (CONAMA). Resolução nº 357, de 17 de março de 2005— Classificação dos corpos de água doce (Art. 14 — Classe 1; Art. 15 — Classe 2). *Diário Oficial da*

União, Brasília, DF, 2005.

CONGALTON, R.G. A review of assessing the accuracy of classifications of remotely sensed data. *Remote Sensing of Environment*, v.37, n.1, p.35-46, 1991.

CORDEIRO, G.G. Qualidade de água para fins de irrigação. Petrolina: Embrapa Semiárido, 2001. 32p. (Documentos; 167).

COX, D. et al. Greenhouse Crops and Floriculture Program. University of Massachusetts Amherst, 2015.

EGBUERI, J.C. et al. A multi-criteria water quality evaluation for human consumption, irrigation and industrial purposes in Umunya area, southeastern Nigeria. *Int. J. Environ. Anal. Chem.*, v.103, p.3351-3375, 2023.

GARCÍA-TEJERO, I.F. et al. Assessing plant water status in a hedgerow olive orchard from thermography at plant level. *Agricultural Water Management*, v.188, p.50-60, 2017.

HAMZAH, F.B. et al. Imputation methods for recovering streamflow observation: a methodological review. *Cogent Environmental Science*, v.6, n.1, 1745133, 2020.

JADHAV, A. et al. Consequences of irrigation water and soil quality: an overview. *Asian Journal of Soil Science and Plant Nutrition*, v.11, n.1, p.435-453, 2025.

JAIN, A.K.; DUBES, R.C. Algorithms for Clustering Data. Prentice Hall, 1988. 320p.

JORDANOV, I.; TARASSOV, E. K-nearest neighbors imputation for missing data in datasets. 2019 IEEE International Conference on Information Technologies (InfoTech-2019), p.1-4, 2019.

KAUFMAN, L.; ROUSSEEUW, P.J. Finding Groups in Data: An Introduction to Cluster Analysis. New York: John Wiley, 1990. 788p.

LEPOT, M. et al. Interpolation in time series: an introductory overview of existing methods, their performance criteria and uncertainty assessment. *Water*, v.9, n.10, p.796, 2017.

LIU, F.T.; TING, K.M.; ZHOU, Z.-H. Isolation Forest. 2008 Eighth IEEE International Conference on Data Mining, p.413-422, 2008.

MACHADO, R.; LOPES, T.; DUARTE, S. Projected climate and land-use change impacts on streamflow: the case study of Piracicaba basin – Brazil. *International Journal of River Basin Management*, p.1-16, 2025.

MORGENTHALER, S. Exploratory data analysis. Wiley Interdisciplinary Reviews: Computational Statistics, v.1, n.1, p.33-44, 2009.

MUNIZ, G.L. et al. Influence of suspended solid particles on calcium carbonate fouling in dripper labyrinths. *Agricultural Water Management*, v.273, art. 107890, 2022.

PCJ. Agência das Bacias PCJ. 2024.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v.12, p.2825-2830, 2011.

POWERS, D.M.W. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, v.2, n.1, p.37-63, 2020.

ROUSSEEUW, P.J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v.20, p.53-65, 1987.

SILVA, R.F. et al. A Data-Driven Method for Water Quality Analysis and Prediction for Localized Irrigation. *AgriEngineering*, v.6, n.2, p.1771-1793, 2024.

TROYANSKAYA, O. et al. Missing value estimation methods for DNA microarrays. *Bioinformatics*, v.17, n.6, p.520-525, 2001.

ZHAO, Y. et al. PyOD: A Python Toolbox for Scalable Outlier Detection. *Journal of Machine Learning Research*, v.20, n.96, p.1-7, 2020.

ZHAO, Y. et al. COPOD: Copula-Based Outlier Detection. *IEEE International Conference on Data Mining (ICDM)*, 2020.

Resultados gerados pelos scripts `run_preprocess.py`, `run_train.py`, `run_evaluate.py`, `run_outliers.py` e `calibrar_contamination.py`. Figuras em `reports/figures/`, tabelas em `reports/tables/` e `data/interim/`. Detalhamento metodológico em `docs/metodologia.md`.